

Método alternativo para Estimação de Estados através de Inteligência Computacional

1stLucas Eduardo Silva Braga

Programa de Pós Graduação em Engenharia Elétrica - PPEE

Universidade Federal de Juiz de Fora

Juiz de Fora - MG, Brasil

braga.lucas@engenharia.ufjf.br

Abstract—Características de Sistemas de Distribuição de Energia Elétrica (SDEE), como carência de medição, requerem métodos de Estimação de Estados (EE) capazes de aferir o estado da rede elétrica com precisão satisfatória. Com isso, métodos têm sido propostos para estimadores de estados, incluindo Redes Neurais Artificiais (RNA), que são ferramentas de inteligência computacional capazes de processar os dados e entregar uma resposta com agilidade, provendo informação útil, como estimativas para variáveis de estado em um SDEE. Este potencial é investigado no presente trabalho, cuja aplicação proposta envolve uma RNA que fornece estimativas para as variáveis de magnitude de tensão nodal, a partir de medidas disponíveis.

Index Terms—Estimação de Estados; Redes Neurais Artificiais; Sistemas de Distribuição;

I. INTRODUÇÃO

O monitoramento de sistemas de distribuição de energia elétrica (SDEE), com base nas informações sobre os níveis de tensão, é essencial para a operação e os processos decisórios, como chaveamentos e reconfigurações, visando à qualidade no fornecimento de energia e estudo de confiabilidade. Diversos métodos estão sendo estudados para realizar a estimação dos estados (EE) de SDEE. Um dos mais utilizados é o método dos mínimos quadrados ponderados (WLS), que se baseia em um processo numérico iterativo. Além do WLS, outras abordagens baseadas em modelos de otimização, como o Fluxo de Potência Ótimo Estendido (E-OPF) [1], têm mostrado eficiência na estimação mesmo com poucas medidas disponíveis. Técnicas de inteligência computacional, como Redes Neurais Artificiais (RNA), também estão ganhando importância.

Um dos desafios para a aplicação de um estimador de estados em tempo hábil em um SDEE é a dimensão das redes elétricas reais. Quanto maior a rede, mais variáveis precisam ser estimadas, aumentando o esforço computacional e podendo afetar a eficiência dos métodos de EE. Diversas pesquisas propõem alternativas para manter a eficiência dentro de padrões aceitáveis. Por exemplo, a divisão da rede em diversas áreas pode reduzir o esforço computacional.

No trabalho de [2], um método que utiliza a matriz de impedâncias e os fasores de tensões nodais é proposto para obter um conjunto suficiente de equações para a estimação de estados. [3] apresentaram um algoritmo baseado no método PASE com filtro de Kalman para EE. [4] propuseram um algoritmo baseado na Série de Taylor de números complexos.

No geral, a adaptação a mudanças topológicas na rede elétrica e a mitigação de erros grosseiros nas medidas são desafios para a EE.

Neste contexto, as Redes Neurais Artificiais (RNA) são promissoras para a EE devido à sua capacidade de rápido processamento e boa eficiência computacional. Além disso, RNAs podem generalizar a partir de uma base de dados conhecida, o que significa que podem lidar bem com dados desconhecidos. Por exemplo, [5] treinaram uma RNA com pseudo-medidas e dados históricos para mapear medidas disponíveis para a [6] também mostraram melhorias nas estimativas usando RNA treinadas com pseudo-medidas.

Outros estudos, como o de [7], utilizaram dados de baixa precisão para treinar uma RNA profunda, capaz de detectar dados irrelevantes antes da EE. [8] focaram no aprendizado de uma RNA com dados de carga na rede. [9] treinaram uma RNA com dados falsos para detectar ataques cibernéticos. [10] usaram RNAs treinadas com fasores de tensão de Unidades de Medição Fasorial (PMU) para estimar margens de carregamento do SDEE, aumentando a precisão na avaliação da estabilidade do sistema.

Este trabalho investiga a aplicação de RNA ao processo de EE usando medidas de abertura angular e magnitude de tensão obtidas de PMUs ou apenas magnitude de tensão de Medidores Inteligentes (MI). Os MI são mais econômicos que PMUs, tornando importante avaliar seu impacto na EE. A RNA proposta é do tipo MultiLayer Perceptron com Aprendizado Supervisionado. A estrutura de RNA proposta não requer pré-processamento de medidas para obtenção de potências nodais, evitando erros nesse processamento. Será avaliado também o tempo computacional para geração de múltiplos cenários, a fim de verificar essa vantagem da RNA sob outros métodos determinísticos que necessitam de maior esforço computacional.

Além desta introdução, o artigo possui outras quatro seções. A Seção apresenta uma fundamentação teórica sobre o processo de EE. A Seção descreve a aplicação de RNA proposta cenários de carga, conjunto amostral. A Seção apresenta estudos de casos e resultados. Por fim, as conclusões são discutidas na Seção.

II. FUNDAMENTAÇÃO TEÓRICA

O problema de Estimação de Estados é avaliado com o auxílio de índices ou métricas. A principal métrica é o erro quadrático formulado em (1) [11], aqui denominado *EEE* (Erro de Estimação de Estados). Além do índice *EEE*, o presente trabalho também avalia mais três métricas propostas por [1]:

- *EMT* (Erro de Módulo de Tensão), formulado em (2);
- *EAF* (Erro de Ângulo de Fase), conforme (3);
- *IGE* (Índice Geral de Estimação), dado pelo somatório das métricas *EEE*, *EMT* e *EAF*, conforme (4).

$$EEE = \sqrt{\sum_{i=1}^k (V_i^* - \hat{V}_i)^2 + \sum_{i=1}^k (\theta_i^* - \hat{\theta}_i)^2} * 100 \quad (1)$$

$$EMT = \max_k \left| \frac{|V_k^*| - |\hat{V}_k|}{|V_k^*|} \right| * 100 \quad (2)$$

$$EAF = \max_k ||\theta_k^* - \hat{\theta}_k|| * 100 \quad (3)$$

$$IGE = EEE + EMT + EAF \quad (4)$$

Em que:

- V_i^* é o módulo de tensão real da barra i .
- \hat{V}_i é o módulo de tensão estimado da barra i .
- θ_i^* é o ângulo de fase real da tensão da barra i .
- $\hat{\theta}_i$ é o ângulo de fase estimado da tensão da barra i .

Verifica-se, portanto, que o índice *IGE* representa um somatório de todas as métricas de erros. Esse índice, porém, generaliza o resultado, sem dar sensibilidade sobre o erro individual dos barramentos do SDEE. Logo, são utilizados, de forma complementar, os índices *EMT* e *EAF*, que trazem informação sobre a pior estimativa, que pode ser útil para mapeamento da fonte de erros no processo de EE.


III. METODOLOGIA PROPOSTA

Esta seção aborda os principais aspectos da rede neural artificial (RNA) proposta para a aplicação, incluindo os dados utilizados para seu treinamento e a arquitetura da RNA. As amostras para treinamento, validação e teste abrangem diferentes cenários de carga do SDEE, visando verificar a capacidade de generalização da RNA. Após o treinamento, a RNA é testada com amostras contendo erros grosseiros em determinadas medidas, para avaliar o impacto desses erros na resposta da RNA e nas métricas de EE previamente definidas.

A. Cenários de Carga

A obtenção dos dados de treinamento, validação e teste da RNA é feita a partir de um gerador de cenários de carregamento do SDEE desenvolvido em *Python* utilizando a ferramenta *PandaPower*, com o cálculo de fluxo de potência para cada cenário gerado. Os cenários são obtidos a partir da modelagem de funções de distribuição normais de probabilidade para as potências ativas de cada barra do SDEE. O

trabalho de [10] considera o percentual de 30% de incerteza para a demanda de sistema de transmissão de energia elétrica. Já o trabalho [1] recomenda a atualização do nível de incerteza para sistemas de Distribuição para 40%. Assim, desvio padrão (σ) considerado foi de 13,33% em relação à média, para que 99,7% dos valores estejam dentro do intervalo de $\pm 40\%$ da média.



Para cada cenário ou amostra, um valor de potência ativa é sorteado dentro da distribuição normal de probabilidades de cada barra, conforme (5). Então, a amostra do valor de potência reativa correspondente é obtida de forma a manter constante o fator de potência fixo de cada barra, conforme (6).

$$P_{i,c} = NP_i \pm 3\sigma \quad \forall c \in Nc \quad (5)$$

$$Q_{i,c} = P_{i,c} \cdot \tan(\arccos(\Psi_i)) \quad \forall c \in Nc \quad (6)$$

Em que:

- $P_{i,c}$ é a potência ativa da barra i em um dado cenário amostral c ;
- $Q_{i,c}$ é a potência reativa da barra i no cenário c ;
- NP_i é a potência ativa nominal da barra i (caso base obtido da literatura);
- σ é o desvio padrão;
- Ψ_i é o fator de potência constante da barra i , o qual foi definido heurísticamente como $FP = 0.92$.

A partir dos valores de $P_{i,c}$ e $Q_{i,c}$ gerados para Nc cenários, são realizados Nc cálculos de fluxo de potência, sendo um para cada cenário c . Dessa forma, são obtidos os valores de $V_{i,c}$ e $\theta_{i,c}$ para cada cenário c entre os Nc cenários, sendo esses os valores de interesse para treinamento, validação e teste da RNA, uma vez que as medidas consideradas são de módulo de tensão e ângulo de fase de tensão provenientes de Unidade de Medição Fasorial (PMU), ou apenas módulo de tensão para medições provenientes de Medidores inteligentes (MI).

Os Nc valores de $V_{i,c}$ e $\theta_{i,c}$, para toda barra i do SDE, conforme descrito na subseção anterior, são divididos em três conjuntos:

- 2000 dos N_c cenários - Conjunto de Treino;
- 500 dos N_c cenários - Conjunto de Validação;
- 1000 dos N_c cenários - Conjunto de Teste.

O maior conjunto, o de treinamento, é aquele a partir do qual a RNA aprende a associação entre os padrões de entrada e de saída do sistema. O segundo conjunto, de validação, é utilizado como critério de convergência para o treinamento, em que um valor N_{vc} é estabelecido como limite de vezes em que a precisão da RNA, durante o treinamento, piora para o conjunto de validação. Caso o limite N_{vc} seja alcançado, o critério mencionado, conhecido como "validação cruzada", é atendido e, então, o treinamento é finalizado. O conjunto de teste, utiliza amostras com as quais a RNA não tem contato em seu treinamento ou validação. Esses dados de teste, por serem, inéditos para a RNA, são úteis para a avaliação da capacidade de generalização da rede já treinada.

B. Tipos de Medidas Consideradas

No presente trabalho, são utilizadas medidas de V_i e/ou θ_i para nas barras i do SDEE em que há disponibilidade de medidores. Os medidores do tipo PMU, apresentam capacidade de medição de módulo e de ângulo de fase da tensão nodal. A precisão de suas medidas, tanto de módulo de tensão, δ_V , quanto de ângulo de fase, δ_θ , é de $\pm 0,4\%$, conforme [12]. Os medidores do tipo MI, são capazes de medir apenas o módulo de tensão, com uma precisão de $\pm 2\%$ [13]

Para a avaliação do estimador de estados via RNA proposto, considera-se o pior caso para o erro nas medidas, ou seja, considera-se que todas estejam em um dos limites, de acordo com o tipo de medidor, conforme a seguir:

- PMUs : $\delta_V = \delta_\theta = +0,4\%$;
- MIs : $\delta_V = +2\%$

Além de retratar o pior caso, este procedimento evita o ruído branco ou gaussiano que seria obtido caso fossem consideradas medidas com erro de $+\delta\%$ ou $-\delta\%$ [14]. Com a inclusão dos erros nas medidas, obtém-se os valores de entrada da RNA proposta, V_i^{err} e θ_i^{err} , conforme formulado em (7) e (8).

$$V_i^{err} = V_i + \delta_V \quad (7)$$

$$\theta_i^{err} = \theta_i + \delta_\theta \quad (8)$$

C. Rede Neural Artificial Proposta

A RNA proposta considera uma topologia conhecida como *MultiLayer Perceptron* (MLP), cuja aprendizagem realizada de forma supervisionada através do algoritmo denominado *backpropagation*. O conjunto de medidas provenientes dos medidores, passando pela aplicação de erros formulada anteriormente, é utilizado como conjunto de dados de entrada da RNA, e o conjunto de saída consiste em vetores com $2 * N_b$ elementos, em que N_b é o número de barras do sistema, cujos valores incluem os módulos de tensão estimada (\hat{V}_i) e de ângulo de fase estimado ($\hat{\theta}_i$) nas N_b barras i do SDE. O erro médio quadrático utilizado como métrica para treinamento e

validação da RNA proposta corresponde ao índice relativo ao erro de estimação de estados, EEE , formulado em (1).

O número de neurônios da camada oculta ($NNCO$) é obtido através de (9), em que NE representa o número de entradas da RNA e NS o número de saídas. Esses valores, por sua vez, são dados por (10) e (11), respectivamente, em que N_{bm} é o número de barras com medição e N_b é o número total de barras do sistema, conforme anteriormente definido.

O presente trabalho propõe uma quantidade de $NNCO$ diferente do proposto por [15], pois na metodologia proposta o número de saídas envolve todas as tensões nodais em módulo e fase cuja quantidade é maior do que o número de saídas de [15] que fornece apenas os módulos de tensão. Assim, de forma empírica, o número de saídas NS é dividido por 3 em (9), a fim de evitar número excessivo de neurônios na camada oculta que comprometesse a eficácia da RNA proposta.

$$NNCO = \frac{2}{3} * NE + \frac{1}{3} * NS \quad (9)$$

$$NE = 2 * N_{bm} \quad (10)$$

$$NS = 2 * N_b \quad (11)$$

A modelagem da RNA proposta é ilustrada em 2 e resumida na Tabela I, em que V_{mi} e θ_{mi} são as medidas de módulo de tensão e ângulo de fase, respectivamente, da barra i . O modelo foi desenvolvido com o auxílio da ferramenta presente no em no ambiente de programação *Python*, mais precisamente, a toolbox *Scikit-Learn*. Durante as iterações no treinamento da RNA, são verificados critérios de convergência como o número máximo de validações cruzadas N_{vc} e número máximo de iterações ou épocas N_{gm} . O treinamento se encerra quando pelo menos um desses critérios é atendido.

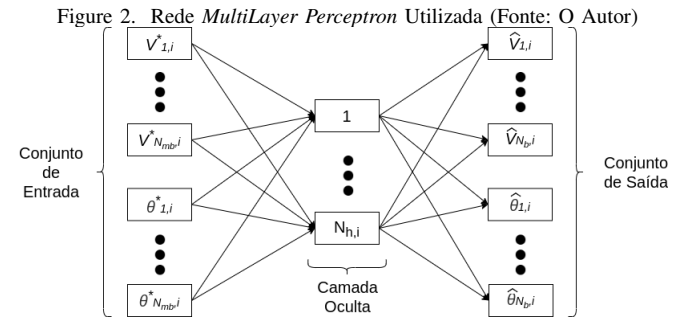


Table I
CONFIGURAÇÃO DA RNA

Parâmetro	Configuração
Tolerância	$1e^{-9}$
Taxa de Aprendizagem	$1e^{-3}$
Número Máx de Validações Cruzadas (N_{vc})	500
Número Máximo de Épocas (N_{gm})	1000

IV. ESTUDO DE CASOS

A. Descrição dos Casos de Estudo

A metodologia proposta foi aplicada no sistema de teste conhecido na literatura, contendo 14 barras [16]. Esse sistema é ilustrado na Figura 5.




Figure 3. Sistema de 14 Barras

Foram obtidos cenários pelas simulações do *pandapower* para diferentes carregamentos variando na distribuição normal.




Figure 4. Distribuição de Potências Ativas para Barra 1 do Sistema




Figure 5. Distribuição de Valores de Tensão para Barra 14 do Sistema

Após treinar a RNA com estes cenários, serão rodados 1000 casos de teste para as seguintes análises:

- **Análise-1:** Alocação PMU segundo [1];
- **Análise-2:** Alocação MI segundo [1];
- **Análise-3:** Alocação PMU segundo [17];
- **Análise-4:** Alocação MI segundo [17];

Para fins de comparação com a literatura, utilizou-se a referência [1] e o trabalho desenvolvido por [17].

Table II
ALOCÇÃO DA MEDIÇÃO

Referência	Barras Monitoradas
[1]	2-10-12-13
[17]	5-6-7-12

Na avaliação da RNA já treinada, obtém-se a média (\hat{x}) e o desvio padrão (σ) das métricas obtidas para as 1000 amostras de teste. Este procedimento é necessário para considerar a incerteza inerente às medidas. Cada valor médio (\hat{x}) é comparado com o respectivo valor de [1], que já considera a incerteza das medidas de forma intrínseca.

B. Resultados

A Tabela III apresenta os resultados obtidos para as Análises-1 a 4, que consideram apenas os erros intrínsecos. As figuras 7 até 10 ilustram um cenário sorteado de cada um dos 4 casos.

Table III
ANÁLISES

Análise-1	IGE	EMT	EAF	EEE
Desvio Padrão (σ)	0.268297	0.258334	0.014171	0.015251
Média (\hat{x})	0.43559	0.367342	0.019344	0.0498
[1]	1.76873	0.42098	0.03754	0.048904
Análise-2	IGE	EMT	EAF	EEE
Desvio Padrão (σ)	9.117887	9.271884	0.392465	0.420524
Média (\hat{x})	2.664328	1.185763	0.388515	1.090049
[1]	1.74393	0.40046	0.02674	1.31673
Análise-3	IGE	EMT	EAF	EEE
Desvio Padrão (σ)	0.49383	0.48384	0.016263	0.014572
Média (\hat{x})	0.819283	0.747689	0.014253	0.05734
Análise-4	IGE	EMT	EAF	EEE
Desvio Padrão (σ)	6.3855	6.2890	0.2175	0.3340
Média (\hat{x})	10.5286	8.9587	0.2613	1.3085




Figure 6. (Análise 1): Boxplot com valores de IGE

Na etapa de geração de 1000 cenários de fluxos de potência que foram usados no grupo de testes, foi medido o tempo de execução dos 1000 casos no pandapower para a comparação com o tempo computacional para rodada das 1000 estimativas da RNA.

Table IV
TEMPO COMPUTACIONAL PARA GERAÇÃO DE 1000 CENÁRIOS

Modelo	Tempo [seg]
Fluxo de Potência <i>PandaPower</i>	31.67905
Rede Neural Treinada	0.0077

Os resultados obtidos mostram que a estratégia de solução através da RNA possui tempo de execução reduzido em relação a métodos conhecidos, como o Fluxo de Potência. A baixa dispersão dos resultados entre diferentes execuções para o caso de medições de PMU, com baixo erro de medição, mostram que o uso de uma RNA previamente treinadas tem uso potencial.




Figure 7. (Análise 1): Comparação da Estimação de Tensão com o valor Real

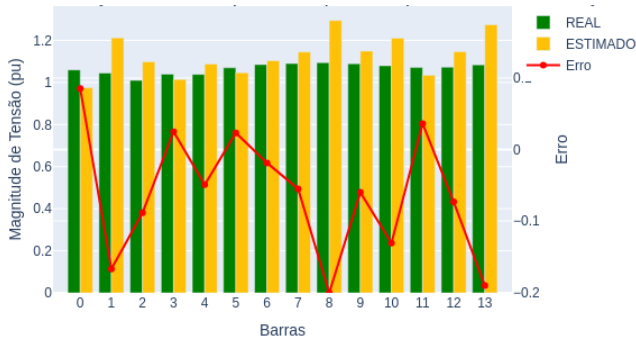


Figure 8. (Análise 2): Comparação da Estimação de Tensão com o valor Real




Figure 9. (Análise 3): Comparação da Estimação de Tensão com o valor Real

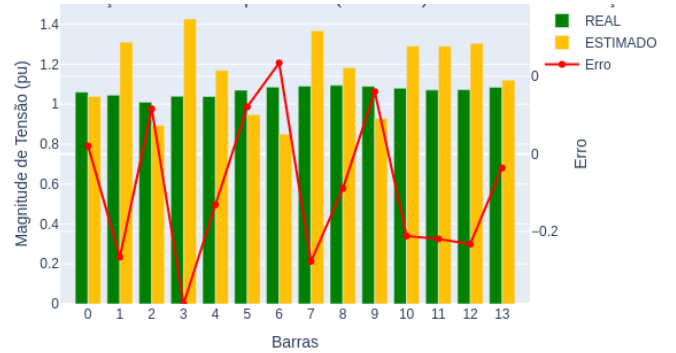


Figure 10. (Análise 4): Comparação da Estimação de Tensão com o valor Real

V. CONCLUSÃO

O presente trabalho demonstrou que há aplicabilidade de redes neurais artificiais ao problema de estimação de estados de redes de distribuição, com pouca disponibilidade de medidas. Foram consideradas medidas de módulo e fase de tensão obtidas de unidades de medição fasorial, bem como de medidores inteligentes, de menor custo de investimento e mais adequados ao contexto da distribuição. A rede neural proposta não requer pré processamento das medidas disponíveis e, com isso, evita a propagação de erros. Para o caso do monitoramento com PMU, a rede neural proposta obteve métricas melhores do que a referência [1]. O uso de MI piora a estimativa com aumento expressivo na média e no desvio padrão do índice de estimação, como esperado, devido ao maior erro associado e ao menor número de informações para o treinamento da RNA, dificultando a aprendizagem. No entanto, este tipo de equipamento é mais frequente em SDEE. A RNA é capaz de fazer estimativas de vários cenários praticamente instantaneamente, enquanto o gerador de cenários demora alguns minutos. Este potencial pode ser utilizado para acelerar o desempenho computacional de metaheurísticas. Esse potencial foi explorado por [17].

REFERENCES

- [1] F. G. Duque, L. W. de Oliveira, E. J. de Oliveira, and A. A. Augusto, "State estimator for electrical distribution systems based on an optimization model," *Electric Power Systems Research*, vol. 152, pp. 122–129, 2017.
- [2] M. Majidi, M. Etezadi-Amoli, and H. Livani, "Distribution system state estimation using compressive sensing," *International Journal of Electrical Power & Energy Systems*, vol. 88, pp. 175–186, 2017.
- [3] C. Carquex, C. Rosenberg, and K. Bhattacharya, "State estimation in power distribution systems based on ensemble kalman filtering," *IEEE Transactions on Power Systems*, vol. 33, no. 6, pp. 6600–6610, 2018.
- [4] Y. Zhang and J. Wang, "Towards highly efficient state estimation with nonlinear measurements in distribution systems," *IEEE Transactions on Power Systems*, vol. 35, no. 3, pp. 2471–2474, 2020.
- [5] A. S. Zamzam, X. Fu, and N. D. Sidiropoulos, "Data-driven learning-based optimization for distribution system state estimation," *IEEE Transactions on Power Systems*, vol. 34, no. 6, pp. 4796–4805, 2019.
- [6] L. Zhang, G. Wang, and G. B. Giannakis, "Distribution system state estimation via data-driven and physics-aware deep neural networks," in *2019 IEEE Data Science Workshop (DSW)*. IEEE, 2019, pp. 258–262.
- [7] K. R. Mestav, J. Luengo-Rozas, and L. Tong, "Bayesian state estimation for unobservable distribution systems via deep learning," *IEEE Transactions on Power Systems*, vol. 34, no. 6, pp. 4910–4920, 2019.
- [8] Z. Cao, Y. Wang, C.-C. Chu, and R. Gadh, "Scalable distribution systems state estimation using long short-term memory networks as surrogates," *IEEE Access*, vol. 8, pp. 23 359–23 368, 2020.
- [9] S. Basumallik, R. Ma, and S. Eftekharijad, "Packet-data anomaly detection in pmu-based state estimator using convolutional neural network," *International Journal of Electrical Power & Energy Systems*, vol. 107, pp. 690–702, 2019.
- [10] S. M. Ashraf, A. Gupta, D. K. Choudhary, and S. Chakrabarti, "Voltage stability monitoring of power systems using reduced network and artificial neural network," *International Journal of Electrical Power & Energy Systems*, vol. 87, pp. 43–51, 2017.
- [11] P. P. Tecchio, R. A. Benedito, and L. F. Alberto, "The behavior of wls state estimator near the maximum loadability point of power systems," in *IEEE PES General Meeting*. IEEE, 2010, pp. 1–6.
- [12] A. Abur and A. G. Exposito, *Power system state estimation: theory and implementation*. CRC press, 2004.
- [13] J. Peppanen, J. Grimaldo, M. J. Reno, S. Grijalva, and R. G. Harley, "Increasing distribution system model accuracy with extensive deployment of smart meters," in *2014 IEEE PES General Meeting—Conference & Exposition*. IEEE, 2014, pp. 1–5.
- [14] S. Wang, J. Zhao, Z. Huang, and R. Diao, "Assessing gaussian assumption of pmu measurement error using field data," *IEEE Transactions on Power Delivery*, vol. 33, no. 6, pp. 3233–3236, 2017.
- [15] J.-H. Menke, N. Bornhorst, and M. Braun, "Distribution system monitoring for smart power grids with distributed generation using artificial neural networks," *International Journal of Electrical Power & Energy Systems*, vol. 113, pp. 472–480, 2019.
- [16] S. Civanlar, J. Grainger, H. Yin, and S. Lee, "Distribution feeder reconfiguration for loss reduction," *IEEE Transactions on Power Delivery*, vol. 3, no. 3, pp. 1217–1223, 1988.
- [17] L. W. d. O. Thales Schuabb de Almeida, Lucas Eduardo Silva Braga, "A hybrid meta-heuristic approach for optimal meter allocation in electric power distribution systems," *Learning and NonLinear Models*, 2021.